# Aprendizado Profundo 1

LSTMs e GRUs

Professor: Lucas Silveira Kupssinskü

# Agenda

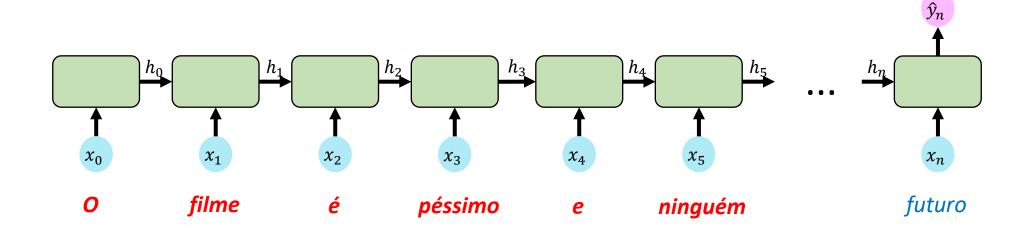
- Problemas em redes recorrentes
- LSTMs
- GRUs

#### Problemas em redes recorrentes

• "O filme é péssimo e ninguém deveria perder tempo assistindo. Contudo eu admiro a tentativa de hollywood de aumentar a representatividade em termos de história e atores, certamente será possível colher frutos sobre essas tentativa em outras obras no futuro"

#### Problemas em redes recorrentes

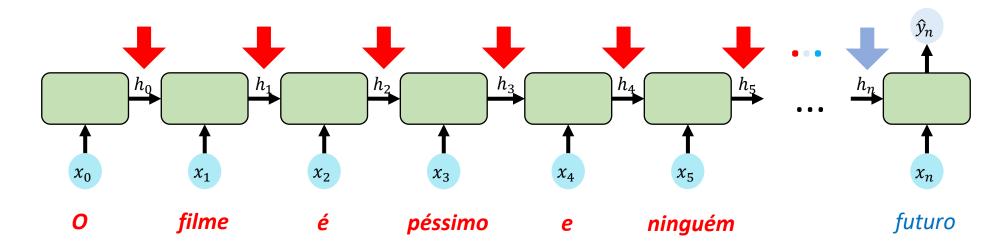
• "O filme é péssimo e ninguém deveria perder tempo assistindo. Contudo eu admiro a tentativa de hollywood de aumentar a representatividade em termos de história e atores, certamente será possível colher frutos sobre essas tentativa em outras obras no futuro"



## Problemas em redes recorrentes

 "O filme é péssimo e ninguém deveria perder tempo assistindo. Contudo eu admiro a tentativa de hollywood de aumentar a representatividade em termos de história e atores, certamente será possível colher frutos sobre essas tentativa em outras obras no futuro"

Repare que, em todos os passos da RNN o estado interno passa por atualizações. Isso dificulta a manutenção de informações por longos períodos de tempo.

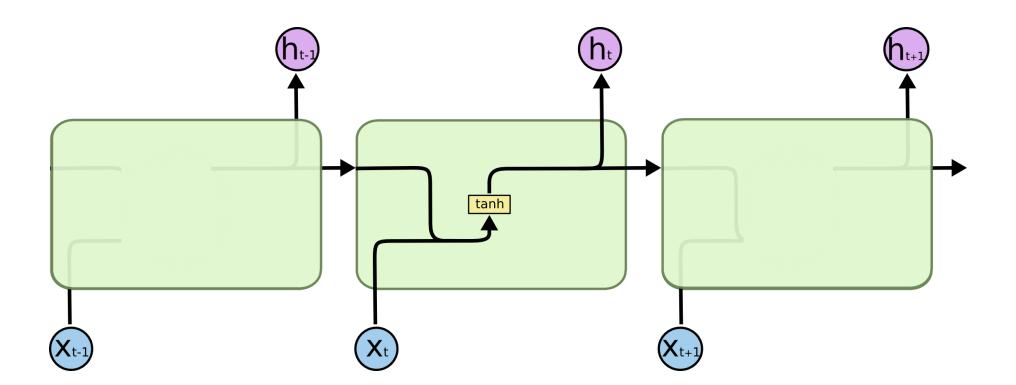


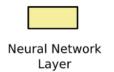
# Solução

- Permitir que a unidade aprenda quando deve ser atualizado e quando deve ser esquecido o estado interno
  - Long Short Term Memory
- É a arquitetura com mais "partes" dentre todas as vistas até agora
  - Contudo, todas as partes se reduzem a operações já conhecidas: multiplicação de matrizes e funções de ativação

# Revisitando RNNs

- Em RNN temos que o estado oculto de um passo anterior  $h_{t-1}$  é usado como entrada para o computar o próximo estado oculto  $h_t$
- Repare que a RNN tem "uma rede densa" dentro





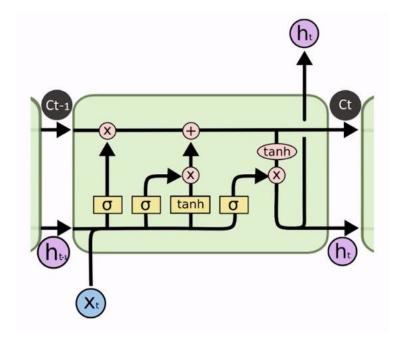


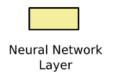






- Mesma ideia da recorrência, mas agora temos um estado oculto  $H_t$  e uma memória (cell state)  $C_t$ 
  - Temos *gates* que tem como objetivo controlar o quanto de cada informação deve ser atualizada (usando uma multiplicação com o resultado de uma sigmoid)
  - Temos uma camada densa com tanh para produzir um novo cell state e um novo hidden state





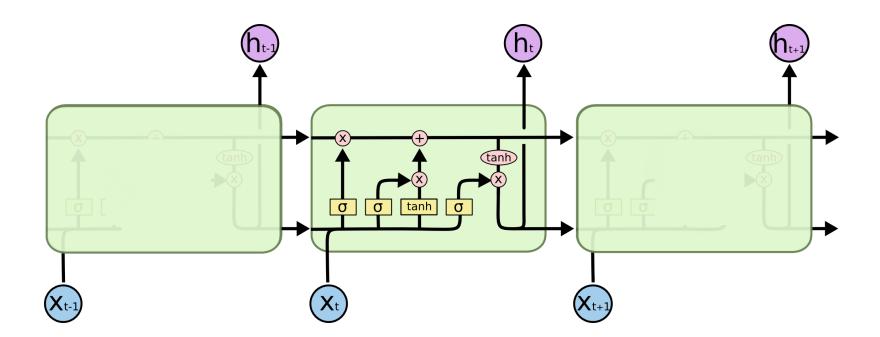


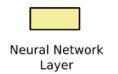






- Mesma ideia da recorrência, mas agora temos quatro camadas densas
  - Três delas fazem função de gates usando ativação sigmoid
    - Forget gate esquecer memória (cell state)
    - Input gate escolher quais partes da entrada devem atualizar o estado atual
    - Output gate escolher quais partes da saída devem fazer parte do próximo estado oculto





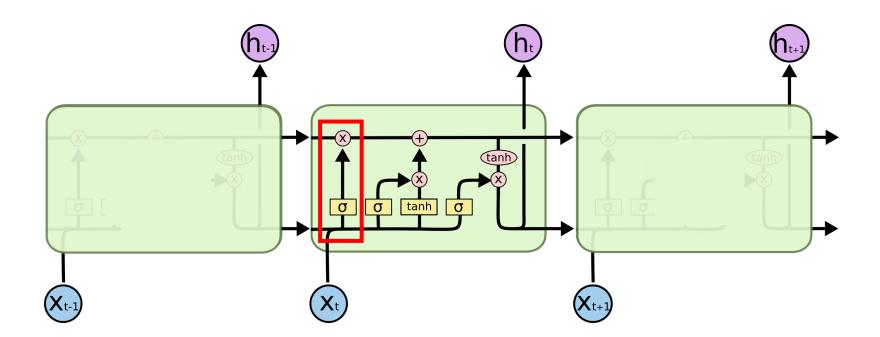


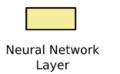






- Mesma ideia da recorrência, mas agora temos quatro camadas densas
  - Três delas fazem função de gates usando ativação sigmoid
    - Forget gate esquecer memória (cell state)
    - Input gate escolher quais partes da entrada devem atualizar o estado atual
    - Output gate escolher quais partes da saída devem fazer parte do próximo estado oculto





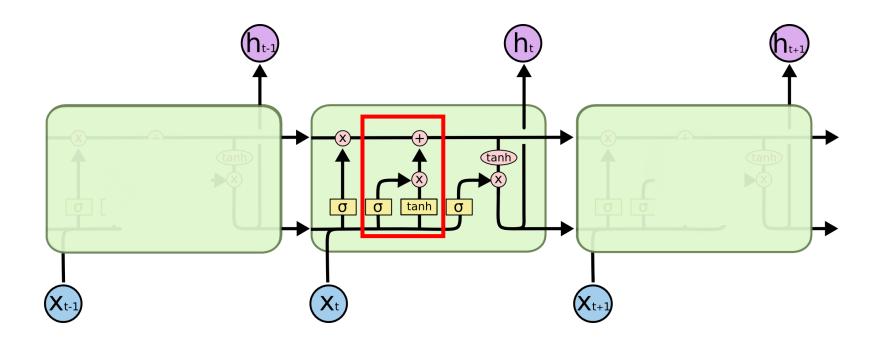


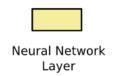






- Mesma ideia da recorrência, mas agora temos quatro camadas densas
  - Três delas fazem função de gates usando ativação sigmoid
    - Forget gate esquecer memória (cell state)
    - Input gate escolher quais partes da entrada devem atualizar o estado atual
    - Output gate escolher quais partes da saída devem fazer parte do próximo estado oculto





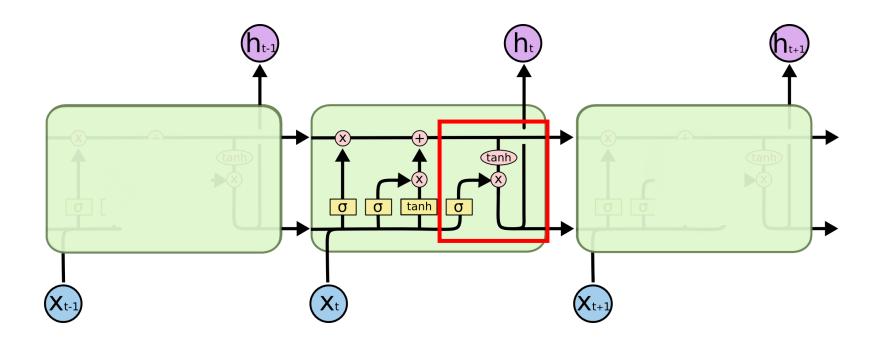


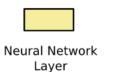






- Mesma ideia da recorrência, mas agora temos quatro camadas densas
  - Três delas fazem função de gates usando ativação sigmoid
    - Forget gate esquecer memória (cell state)
    - Input gate escolher quais partes da entrada devem atualizar o estado atual
    - Output gate escolher quais partes da saída devem fazer parte do próximo estado oculto





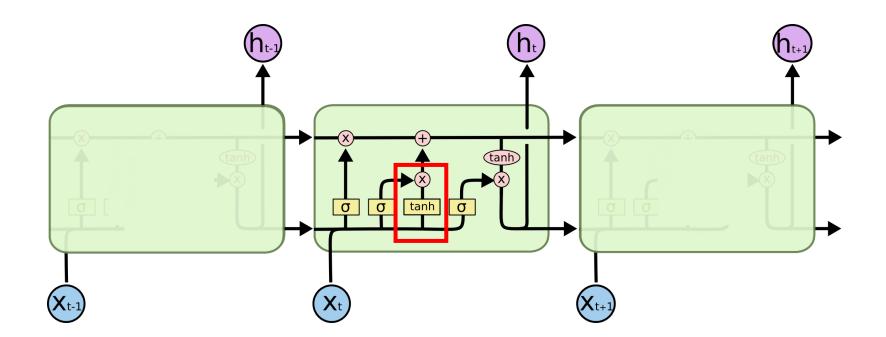


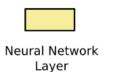






- Mesma ideia da recorrência, mas agora temos quatro camadas densas
  - Uma delas aplica uma transformação não linear na entrada + estado oculto anterior





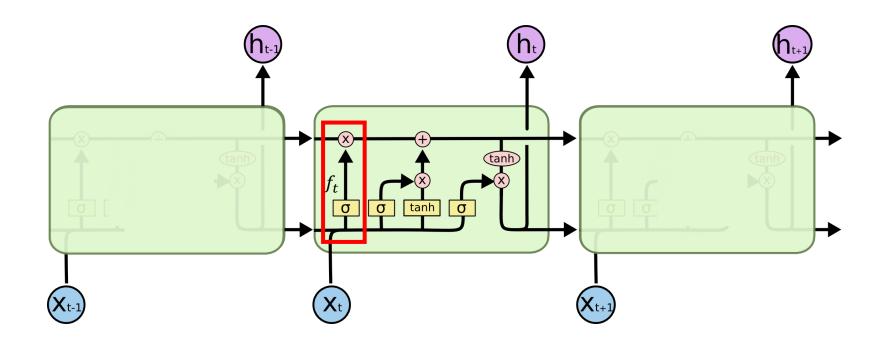


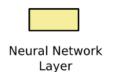






- Vamos passar novamente por cada passo, porém agora vamos detalhar as operações
  - $f_t = \sigma(\theta_f[h_{t-1}, x_t] + b_f)$





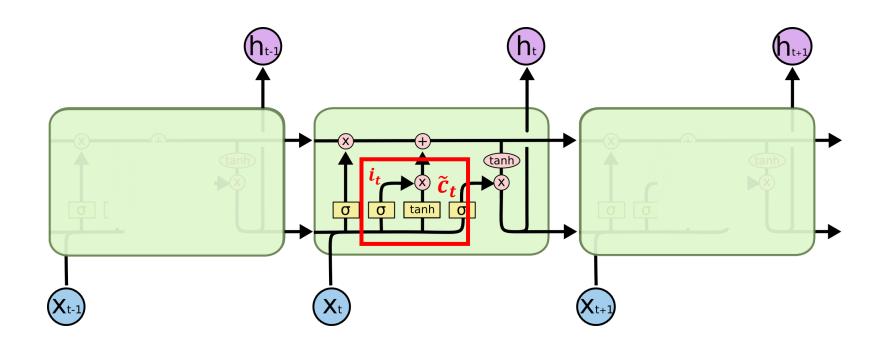








- Vamos passar novamente por cada passo, porém agora vamos detalhar as operações
  - $i_t = \sigma(\theta_i[h_{t-1}, x_t] + b_i)$
  - $\tilde{c}_t = tanh(\theta_c[h_{t-1}, x_t] + b_c)$



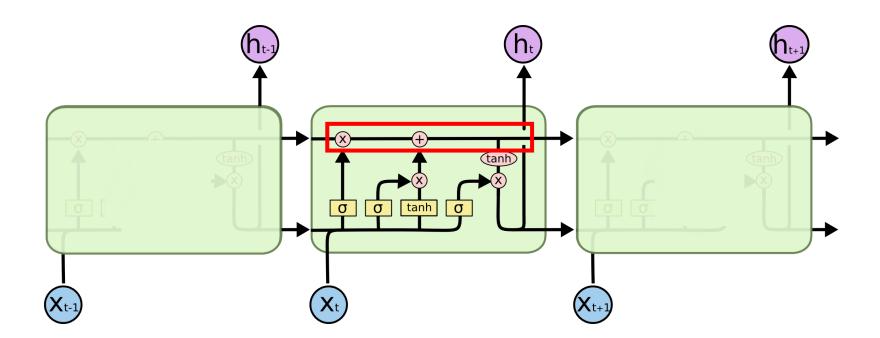


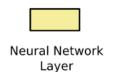






- Vamos passar novamente por cada passo, porém agora vamos detalhar as operações
  - $c_t = f_t * c_{t-1} + i_t * \tilde{c}_t$





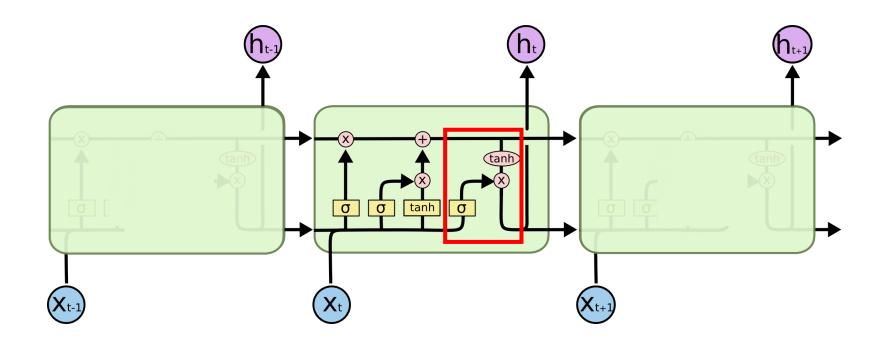


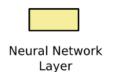






- Vamos passar novamente por cada passo, porém agora vamos detalhar as operações
  - $o_t = \sigma(\theta_o[h_{t-1}, x_t] + b_o)$
  - $h_t = o_t * \tanh(c_t)$





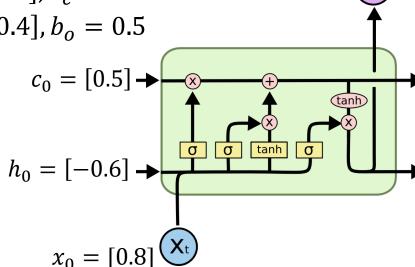








- Agora vamos usar alguns valores para ver as coisas acontecendo
  - $c_0 = [0.5]$
  - $h_0 = [-0.6,]$
  - $x_0 = [0.8]$
  - $\theta_f = [0.5, -0.5], b_f = 0.3$
  - $\theta_i = [0.3, -0.4], b_i = 0.5$
  - $\theta_c = [0.1, -0.3], b_c = 0.7$
  - $\theta_o = [-0.5, 0.4], b_o = 0.5$



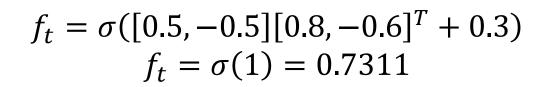


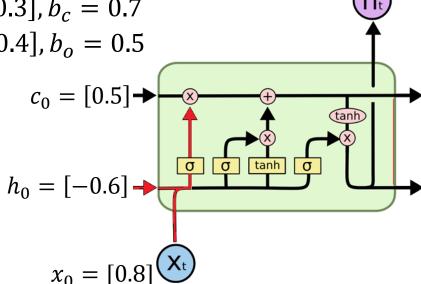






- Agora vamos usar alguns valores para ver as coisas acontecendo
  - $c_0 = [0.5]$
  - $h_0 = [-0.6,]$
  - $x_0 = [0.8]$
  - $\theta_f = [0.5, -0.5], b_f = 0.3$
  - $\theta_i = [0.3, -0.4], b_i = 0.5$
  - $\theta_c = [0.1, -0.3], b_c = 0.7$
  - $\theta_o = [-0.5, 0.4], b_o = 0.5$

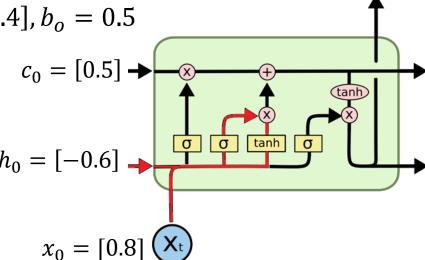






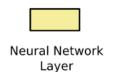


- Agora vamos usar alguns valores para ver as coisas acontecendo
  - $c_0 = [0.5]$
  - $h_0 = [-0.6,]$
  - $x_0 = [0.8]$
  - $\theta_f = [0.5, -0.5], b_f = 0.3$
  - $\theta_i = [0.3, -0.4], b_i = 0.5$
  - $\theta_c = [0.1, -0.3], b_c = 0.7$
  - $\theta_o = [-0.5, 0.4], b_o = 0.5$



$$i_t = \sigma([0.3, -0.4][0.8, -0.6]^T + 0.5)$$
  
 $i_t = \sigma(0.98) = 0.7271$ 

$$\tilde{c}_t = tanh([0.1, -0.3][0.8, -0.6]^T + 0.7)$$
  
 $\tilde{c}_t = tanh(0.96) = 0.7443$ 



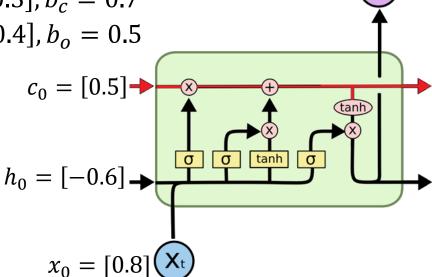








- Agora vamos usar alguns valores para ver as coisas acontecendo
  - $c_0 = [0.5]$
  - $h_0 = [-0.6,]$
  - $x_0 = [0.8]$
  - $\theta_f = [0.5, -0.5], b_f = 0.3$
  - $\theta_i = [0.3, -0.4], b_i = 0.5$
  - $\theta_c = [0.1, -0.3], b_c = 0.7$
  - $\theta_o = [-0.5, 0.4], b_o = 0.5$



$$c_t = 0.7311 * 0.5 + 0.7271 * 0.7443$$
  
 $c_t = 0.9067$ 

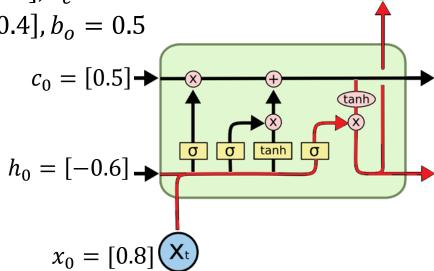








- Agora vamos usar alguns valores para ver as coisas acontecendo
  - $c_0 = [0.5]$
  - $h_0 = [-0.6,]$
  - $x_0 = [0.8]$
  - $\theta_f = [0.5, -0.5], b_f = 0.3$
  - $\theta_i = [0.3, -0.4], b_i = 0.5$
  - $\theta_c = [0.1, -0.3], b_c = 0.7$
  - $\theta_o = [-0.5, 0.4], b_o = 0.5$



$$o_t = \sigma([-0.5, 0.4][0.8, -0.6]^T + 0.5)$$
  
 $o_t = 0.4651$ 

$$h_t = 0.4651 * \tanh(0,9067)$$
  
 $h_t = 0.7195$ 

- Podemos otimizar o Forward Pass para fazer apenas duas multiplicações de matrizes sem concatenação
- is: input size
- hs: hidden size
- $W_{is \times hs *4}$
- $U_{hs \times hs *4}$
- $b_{hs*4}$

• 
$$c_0 = [0.5]$$

• 
$$h_0 = [-0.6,]$$

• 
$$x_0 = [0.8]$$

• 
$$U = [0.5, 0.3, 0.1, -0.5]$$

• 
$$V = [-0.5, -0.4, -0.3, 0.4]$$

• 
$$b = [0.3, 0.5, 0.7, 0.5]$$

$$A_{t} = x_{0}W + h_{0}U + b$$

$$f_{t} = \sigma(A_{t}[:, 0: hs])$$

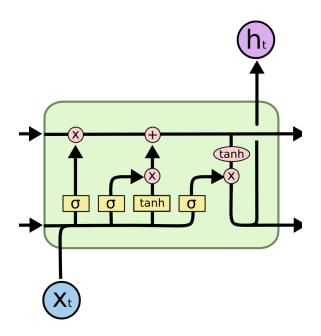
$$i_{t} = \sigma(A_{t}[:, hs: hs * 2])$$

$$o_{t} = \sigma(A_{t}[:, hs * 2: hs * 3])$$

$$\tilde{c}_{t} = tanh(A_{t}[:, hs * 3: hs * 4])$$

$$c_{t} = f_{t} * c_{t-1} + i_{t} * \tilde{c}_{t}$$

$$h_{t} = o_{t} * tanh(c_{t})$$



- is: input size
- *hs*: hidden size
- $W_{is \times hs *4}$
- $U_{hs \times hs *4}$
- $b_{hs*4}$

```
A_{t} = x_{0}W + h_{0}U + b
f_{t} = \sigma(A_{t}[:, 0: hs])
i_{t} = \sigma(A_{t}[:, hs: hs * 2])
o_{t} = \sigma(A_{t}[:, hs * 2: hs * 3])
\tilde{c}_{t} = tanh(A_{t}[:, hs * 3: hs * 4])
c_{t} = f_{t} * c_{t-1} + i_{t} * \tilde{c}_{t}
h_{t} = o_{t} * tanh(c_{t})
```

```
class MyLSTM(nn.Module):
  def __init__(self, input_sz, hidden_sz):
     super().__init__()
     self.input_sz = input_sz
     self.hidden size = hidden sz
     self.W = nn.Parameter(torch.Tensor(input_sz, hidden_sz * 4))
     self.U = nn.Parameter(torch.Tensor(hidden_sz, hidden_sz * 4))
     self.bias = nn.Parameter(torch.Tensor(hidden_sz * 4))
     self.init_weights() # not shown
  def forward(self, x):
     """Assumes x is of shape (batch, sequence, feature)"""
     bs, seq_sz, _= x.size()
     hidden_seq = []
     h_t, c_t = (torch.zeros(bs, self.hidden_size).to(x.device),
             torch.zeros(bs, self.hidden_size).to(x.device))
     HS = self.hidden size
     for t in range(seg_sz):
        x_t = x[:, t, :]
        gates = x_t @ self.W + h_t @ self.U + self.bias
        i_t, f_t, g_t, o_t = (
           torch.sigmoid(gates[:, :HS]), # input
           torch.sigmoid(gates[:, HS:HS*2]), # forget
           torch.tanh(gates[:, HS*2:HS*3]),
           torch.sigmoid(gates[:, HS*3:]), # output
        c_t = f_t * c_t + i_t * g_t
        h_t = o_t * torch.tanh(c_t)
        hidden_seq.append(h_t.unsqueeze(0))
     hidden_seg = torch.cat(hidden_seg, dim=0)
     # reshape from shape (sequence, batch, feature) to (batch, sequence, feature)
     hidden_seq = hidden_seq.transpose(0, 1).contiguous()
     return hidden_seq, (h_t, c_t)
```

- *is*: input size
- *hs*: hidden size
- $W_{is \times hs *4}$
- $U_{hs \times hs *4}$
- $b_{hs*4}$

```
A_{t} = x_{0}W + h_{0}U + b
f_{t} = \sigma(A_{t}[:, 0: hs])
i_{t} = \sigma(A_{t}[:, hs: hs * 2])
o_{t} = \sigma(A_{t}[:, hs * 2: hs * 3])
\tilde{c}_{t} = tanh(A_{t}[:, hs * 3: hs * 4])
c_{t} = f_{t} * c_{t-1} + i_{t} * \tilde{c}_{t}
h_{t} = o_{t} * tanh(c_{t})
```

```
class MyLSTM(nn.Module):
  def __init__(self, input_sz, hidden_sz):
     super().__init__()
     self.input_sz = input_sz
     self.hidden size = hidden sz
     self.W = nn.Parameter(torch.Tensor(input_sz, hidden_sz * 4))
     self.U = nn.Parameter(torch.Tensor(hidden_sz, hidden_sz * 4))
     self.bias = nn.Parameter(torch.Tensor(hidden_sz * 4))
     self.init_weights() # not shown
  def forward(self, x):
     """Assumes x is of shape (batch, sequence, feature)"""
     bs, seq_sz, _= x.size()
     hidden_seq = []
     h_t, c_t = (torch.zeros(bs, self.hidden_size).to(x.device),
             torch.zeros(bs, self.hidden_size).to(x.device))
     HS = self.hidden size
     for t in range(seg_sz):
        x_t = x[:, t, :]
        gates = x_t @ self.W + h_t @ self.U + self.bias
        i_t, f_t, g_t, o_t = (
           torch.sigmoid(gates[:, :HS]), # input
           torch.sigmoid(gates[:, HS:HS*2]), # forget
           torch.tanh(gates[:, HS*2:HS*3]),
           torch.sigmoid(gates[:, HS*3:]), # output
        c_t = f_t * c_t + i_t * g_t
        h_t = o_t * torch.tanh(c_t)
        hidden_seq.append(h_t.unsqueeze(0))
     hidden_seg = torch.cat(hidden_seg, dim=0)
     # reshape from shape (sequence, batch, feature) to (batch, sequence, feature)
     hidden_seq = hidden_seq.transpose(0, 1).contiguous()
     return hidden_seq, (h_t, c_t)
```

- is: input size
- *hs*: hidden size
- $W_{i,s \times h,s *4}$
- $U_{hs \times hs *4}$
- *b*<sub>*hs*\*4</sub>

```
A_{t} = x_{0}W + h_{0}U + b
f_{t} = \sigma(A_{t}[:, 0: hs])
i_{t} = \sigma(A_{t}[:, hs: hs * 2])
o_{t} = \sigma(A_{t}[:, hs * 2: hs * 3])
\tilde{c}_{t} = tanh(A_{t}[:, hs * 3: hs * 4])
c_{t} = f_{t} * c_{t-1} + i_{t} * \tilde{c}_{t}
h_{t} = o_{t} * tanh(c_{t})
```

```
class MyLSTM(nn.Module):
  def __init__(self, input_sz, hidden_sz):
     super().__init__()
     self.input_sz = input_sz
     self.hidden size = hidden sz
     self.W = nn.Parameter(torch.Tensor(input_sz, hidden_sz * 4))
     self.U = nn.Parameter(torch.Tensor(hidden_sz, hidden_sz * 4))
     self.bias = nn.Parameter(torch.Tensor(hidden_sz * 4))
     self.init_weights() # not shown
  def forward(self, x):
     """Assumes x is of shape (batch, sequence, feature)"""
     bs, seq_sz, _ = x.size()
     hidden_seq = []
     h_t, c_t = (torch.zeros(bs, self.hidden_size).to(x.device),
             torch.zeros(bs, self.hidden_size).to(x.device))
     HS = self.hidden size
     for t in range(seg_sz):
        x_t = x[:, t, :]
        gates = x_t @ self.W + h_t @ self.U + self.bias
        i_t, f_t, g_t, o_t = (
           torch.sigmoid(gates[:, :HS]), # input
           torch.sigmoid(gates[:, HS:HS*2]), # forget
           torch.tanh(gates[:, HS*2:HS*3]),
           torch.sigmoid(gates[:, HS*3:]), # output
        c_t = f_t * c_t + i_t * g_t
        h_t = o_t * torch.tanh(c_t)
        hidden_seq.append(h_t.unsqueeze(0))
     hidden_seg = torch.cat(hidden_seg, dim=0)
     # reshape from shape (sequence, batch, feature) to (batch, sequence, feature)
     hidden_seq = hidden_seq.transpose(0, 1).contiguous()
     return hidden_seq, (h_t, c_t)
```

- is: input size
- *hs*: hidden size
- $W_{is \times hs *4}$
- $U_{hs \times hs *4}$
- $b_{h,s*4}$

```
A_{t} = x_{0}W + h_{0}U + b
f_{t} = \sigma(A_{t}[:, 0: hs])
i_{t} = \sigma(A_{t}[:, hs: hs * 2])
o_{t} = \sigma(A_{t}[:, hs * 2: hs * 3])
\tilde{c}_{t} = tanh(A_{t}[:, hs * 3: hs * 4])
c_{t} = f_{t} * c_{t-1} + i_{t} * \tilde{c}_{t}
h_{t} = o_{t} * tanh(c_{t})
```

```
class MyLSTM(nn.Module):
  def __init__(self, input_sz, hidden_sz):
     super().__init__()
     self.input_sz = input_sz
     self.hidden size = hidden sz
     self.W = nn.Parameter(torch.Tensor(input_sz, hidden_sz * 4))
     self.U = nn.Parameter(torch.Tensor(hidden_sz, hidden_sz * 4))
     self.bias = nn.Parameter(torch.Tensor(hidden_sz * 4))
     self.init_weights() # not shown
  def forward(self, x):
     """Assumes x is of shape (batch, sequence, feature)"""
     bs, seq_sz, _= x.size()
     hidden_seq = []
     h_t, c_t = (torch.zeros(bs, self.hidden_size).to(x.device),
             torch.zeros(bs, self.hidden_size).to(x.device))
     HS = self.hidden size
     for t in range(seg_sz):
        x_t = x[:, t, :]
        gates = x_t @ self.W + h_t @ self.U + self.bias
        i_t, f_t, g_t, o_t = (
           torch.sigmoid(gates[:, :HS]), # input
           torch.sigmoid(gates[:, HS:HS*2]), # forget
           torch.tanh(gates[:, HS*2:HS*3]),
           torch.sigmoid(gates[:, HS*3:]), # output
        c_t = f_t * c_t + i_t * g_t
        h_t = o_t * torch.tanh(c_t)
        hidden_seq.append(h_t.unsqueeze(0))
     hidden_seg = torch.cat(hidden_seg, dim=0)
     # reshape from shape (sequence, batch, feature) to (batch, sequence, feature)
     hidden_seq = hidden_seq.transpose(0, 1).contiguous()
     return hidden_seq, (h_t, c_t)
```

- is: input size
- *hs*: hidden size
- $W_{is \times hs *4}$
- $U_{hs \times hs *4}$
- $b_{hs*4}$

```
A_{t} = x_{0}W + h_{0}U + b
f_{t} = \sigma(A_{t}[:, 0: hs])
i_{t} = \sigma(A_{t}[:, hs: hs * 2])
o_{t} = \sigma(A_{t}[:, hs * 2: hs * 3])
\tilde{c}_{t} = tanh(A_{t}[:, hs * 3: hs * 4])
c_{t} = f_{t} * c_{t-1} + i_{t} * \tilde{c}_{t}
h_{t} = o_{t} * tanh(c_{t})
```

```
class MyLSTM(nn.Module):
  def __init__(self, input_sz, hidden_sz):
     super().__init__()
     self.input_sz = input_sz
     self.hidden size = hidden sz
     self.W = nn.Parameter(torch.Tensor(input_sz, hidden_sz * 4))
     self.U = nn.Parameter(torch.Tensor(hidden_sz, hidden_sz * 4))
     self.bias = nn.Parameter(torch.Tensor(hidden_sz * 4))
     self.init_weights() # not shown
  def forward(self, x):
     """Assumes x is of shape (batch, sequence, feature)"""
     bs, seq_sz, _= x.size()
     hidden_seq = []
     h_t, c_t = (torch.zeros(bs, self.hidden_size).to(x.device),
             torch.zeros(bs, self.hidden_size).to(x.device))
     HS = self.hidden size
     for t in range(seg_sz):
        x_t = x[:, t, :]
        gates = x_t @ self.W + h_t @ self.U + self.bias
        i_t, f_t, g_t, o_t = (
           torch.sigmoid(gates[:, :HS]), # input
           torch.sigmoid(gates[:, HS:HS*2]), # forget
           torch.tanh(gates[:, HS*2:HS*3]),
           torch.sigmoid(gates[:, HS*3:]), # output
        c_t = f_t * c_t + i_t * g_t
        h_t = o_t * torch.tanh(c_t)
        hidden_seq.append(h_t.unsqueeze(0))
     hidden_seg = torch.cat(hidden_seg, dim=0)
     # reshape from shape (sequence, batch, feature) to (batch, sequence, feature)
     hidden_seq = hidden_seq.transpose(0, 1).contiguous()
     return hidden_seq, (h_t, c_t)
```

- is: input size
- *hs*: hidden size
- $W_{is \times hs *4}$
- $U_{hs \times hs *4}$
- $b_{hs*4}$

```
A_{t} = x_{0}W + h_{0}U + b
f_{t} = \sigma(A_{t}[:, 0: hs])
i_{t} = \sigma(A_{t}[:, hs: hs * 2])
o_{t} = \sigma(A_{t}[:, hs * 2: hs * 3])
\tilde{c}_{t} = tanh(A_{t}[:, hs * 3: hs * 4])
c_{t} = f_{t} * c_{t-1} + i_{t} * \tilde{c}_{t}
h_{t} = o_{t} * tanh(c_{t})
```

```
class MyLSTM(nn.Module):
  def __init__(self, input_sz, hidden_sz):
     super().__init__()
     self.input_sz = input_sz
     self.hidden size = hidden sz
     self.W = nn.Parameter(torch.Tensor(input_sz, hidden_sz * 4))
     self.U = nn.Parameter(torch.Tensor(hidden_sz, hidden_sz * 4))
     self.bias = nn.Parameter(torch.Tensor(hidden_sz * 4))
     self.init_weights() # not shown
  def forward(self, x):
     """Assumes x is of shape (batch, sequence, feature)"""
     bs, seq_sz, _= x.size()
     hidden_seq = []
     h_t, c_t = (torch.zeros(bs, self.hidden_size).to(x.device),
             torch.zeros(bs, self.hidden_size).to(x.device))
     HS = self.hidden size
     for t in range(seg_sz):
       x_t = x[:, t, :]
       gates = x_t @ self.W + h_t @ self.U + self.bias
        i_t, f_t, g_t, o_t = (
           torch.sigmoid(gates[:, :HS]), # input
           torch.sigmoid(gates[:, HS:HS*2]), # forget
           torch.tanh(gates[:, HS*2:HS*3]),
           torch.sigmoid(gates[:, HS*3:]), # output
        c_t = f_t * c_t + i_t * g_t
        h_t = o_t * torch.tanh(c_t)
        hidden_seq.append(h_t.unsqueeze(0))
     hidden_seg = torch.cat(hidden_seg, dim=0)
     # reshape from shape (sequence, batch, feature) to (batch, sequence, feature)
     hidden_seq = hidden_seq.transpose(0, 1).contiguous()
     return hidden_seq, (h_t, c_t)
```

- is: input size
- *hs*: hidden size
- $W_{is \times hs *4}$
- $U_{hs \times hs *4}$
- *b*<sub>*hs*\*4</sub>

```
A_{t} = x_{0}W + h_{0}U + b
f_{t} = \sigma(A_{t}[:, 0: hs])
i_{t} = \sigma(A_{t}[:, hs: hs * 2])
o_{t} = \sigma(A_{t}[:, hs * 2: hs * 3])
\tilde{c}_{t} = tanh(A_{t}[:, hs * 3: hs * 4])
c_{t} = f_{t} * c_{t-1} + i_{t} * \tilde{c}_{t}
h_{t} = o_{t} * tanh(c_{t})
```

```
class MyLSTM(nn.Module):
  def __init__(self, input_sz, hidden_sz):
     super().__init__()
     self.input_sz = input_sz
     self.hidden size = hidden sz
     self.W = nn.Parameter(torch.Tensor(input_sz, hidden_sz * 4))
     self.U = nn.Parameter(torch.Tensor(hidden_sz, hidden_sz * 4))
     self.bias = nn.Parameter(torch.Tensor(hidden_sz * 4))
     self.init_weights() # not shown
  def forward(self, x):
     """Assumes x is of shape (batch, sequence, feature)"""
     bs, seq_sz, _= x.size()
     hidden_seq = []
     h_t, c_t = (torch.zeros(bs, self.hidden_size).to(x.device),
             torch.zeros(bs, self.hidden_size).to(x.device))
     HS = self.hidden size
     for t in range(seg_sz):
        x_t = x[:, t, :]
        gates = x t @ self W + h t @ self U + self bias
       i_t, f_t, g_t, o_t = (
           torch.sigmoid(gates[:, :HS]), # input
           torch.sigmoid(gates[:, HS:HS*2]), # forget
          torch.tanh(gates[:, HS*2:HS*3]),
           torch.sigmoid(gates[:, HS*3:]), # output
        c_t = f_t * c_t + i_t * g_t
        h_t = o_t * torch.tanh(c_t)
        hidden_seq.append(h_t.unsqueeze(0))
     hidden_seg = torch.cat(hidden_seg, dim=0)
     # reshape from shape (sequence, batch, feature) to (batch, sequence, feature)
     hidden_seq = hidden_seq.transpose(0, 1).contiguous()
     return hidden_seq, (h_t, c_t)
```

- is: input size
- *hs*: hidden size
- $W_{is \times hs *4}$
- $U_{hs \times hs *4}$
- $b_{hs*4}$

```
A_{t} = x_{0}W + h_{0}U + b
f_{t} = \sigma(A_{t}[:, 0: hs])
i_{t} = \sigma(A_{t}[:, hs: hs * 2])
o_{t} = \sigma(A_{t}[:, hs * 2: hs * 3])
\tilde{c}_{t} = tanh(A_{t}[:, hs * 3: hs * 4])
c_{t} = f_{t} * c_{t-1} + i_{t} * \tilde{c}_{t}
h_{t} = o_{t} * tanh(c_{t})
```

```
class MyLSTM(nn.Module):
  def __init__(self, input_sz, hidden_sz):
     super().__init__()
     self.input_sz = input_sz
     self.hidden size = hidden sz
     self.W = nn.Parameter(torch.Tensor(input_sz, hidden_sz * 4))
     self.U = nn.Parameter(torch.Tensor(hidden_sz, hidden_sz * 4))
     self.bias = nn.Parameter(torch.Tensor(hidden_sz * 4))
     self.init_weights() # not shown
  def forward(self, x):
     """Assumes x is of shape (batch, sequence, feature)"""
     bs, seq_sz, _= x.size()
     hidden_seq = []
     h_t, c_t = (torch.zeros(bs, self.hidden_size).to(x.device),
             torch.zeros(bs, self.hidden_size).to(x.device))
     HS = self.hidden size
     for t in range(seg_sz):
        x_t = x[:, t, :]
        gates = x_t @ self.W + h_t @ self.U + self.bias
        i_t, f_t, g_t, o_t = (
           torch.sigmoid(gates[:, :HS]), # input
           torch.sigmoid(gates[:, HS:HS*2]), # forget
           torch.tanh(gates[:, HS*2:HS*3]),
           torch.sigmoid(gates[:, HS*3:]), # output
        c_t = f_t * c_t + i_t * g_t
        h_t = o_t * torch.tanh(c_t)
        hidden_seg.append(h_t.unsqueeze(0))
     hidden_seg = torch.cat(hidden_seg, dim=0)
     # reshape from shape (sequence, batch, feature) to (batch, sequence, feature)
     hidden_seq = hidden_seq.transpose(0, 1).contiguous()
     return hidden_seq, (h_t, c_t)
```

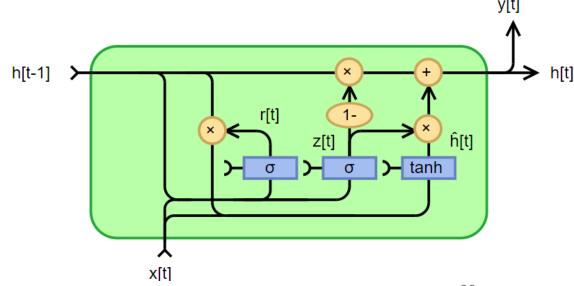
- is: input size
- *hs*: hidden size
- $W_{is \times hs *4}$
- $U_{hs \times hs *4}$
- $b_{hs*4}$

```
A_{t} = x_{0}W + h_{0}U + b
f_{t} = \sigma(A_{t}[:, 0: hs])
i_{t} = \sigma(A_{t}[:, hs: hs * 2])
o_{t} = \sigma(A_{t}[:, hs * 2: hs * 3])
\tilde{c}_{t} = tanh(A_{t}[:, hs * 3: hs * 4])
c_{t} = f_{t} * c_{t-1} + i_{t} * \tilde{c}_{t}
h_{t} = o_{t} * tanh(c_{t})
```

```
class MyLSTM(nn.Module):
  def __init__(self, input_sz, hidden_sz):
     super().__init__()
     self.input_sz = input_sz
     self.hidden size = hidden sz
     self.W = nn.Parameter(torch.Tensor(input_sz, hidden_sz * 4))
     self.U = nn.Parameter(torch.Tensor(hidden_sz, hidden_sz * 4))
     self.bias = nn.Parameter(torch.Tensor(hidden_sz * 4))
     self.init_weights() # not shown
  def forward(self, x):
     """Assumes x is of shape (batch, sequence, feature)"""
     bs, seq_sz, _= x.size()
     hidden_seq = []
     h_t, c_t = (torch.zeros(bs, self.hidden_size).to(x.device),
             torch.zeros(bs, self.hidden_size).to(x.device))
     HS = self.hidden size
     for t in range(seg_sz):
        x_t = x[:, t, :]
        gates = x_t @ self.W + h_t @ self.U + self.bias
        i_t, f_t, g_t, o_t = (
           torch.sigmoid(gates[:, :HS]), # input
           torch.sigmoid(gates[:, HS:HS*2]), # forget
           torch.tanh(gates[:, HS*2:HS*3]),
           torch.sigmoid(gates[:, HS*3:]), # output
        c_t = f_t * c_t + i_t * q_t
       h_t = o_t * torch.tanh(c_t)
        hidden_seg.append(h_t.unsqueeze(0))
     hidden_seg = torch.cat(hidden_seg, dim=0)
     # reshape from shape (sequence, batch, feature) to (batch, sequence, feature)
     hidden_seq = hidden_seq.transpose(0, 1).contiguous()
     return hidden_seq, (h_t, c_t)
```

#### **GRU**

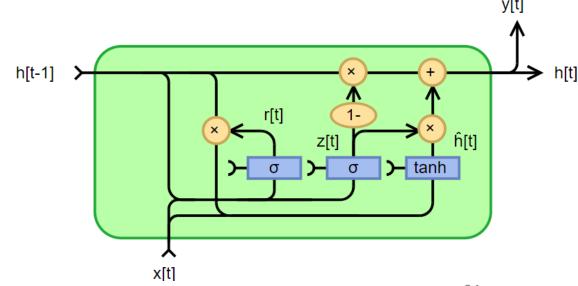
- Gated Recurrent Unit foi introduzida por Cho et al em 2014
- É considerada uma versão simplificada da LSTM
- Não mantemos um c e um h separados
  - Ao invés disso temos uma reset gate r e uma update gate z



33

#### **GRU**

- Reset gate
  - $r_t = \sigma(w_r[x_t, h_{t-1}] + b_r)$
- Update gate
  - $z_t = \sigma(w_z[x_t, h_{t-1}] + b_z)$
- Hidden Candidate
  - $\tilde{h}_t = \tanh(w_h[x_t, r_t * h_{t-1}] + b_h)$
- $h_t = h_{t-1} * (1 z_t) + z_t * \tilde{h}_t$



34

### Referências:

- Sugere-se a leitura de:
  - Capítulo 10 GOODFELLOW, I., BENGIO, Y., COURVILLE, A. Deep Learning. MIT Press, 775p., 2016. (https://www.deeplearningbook.org/)
- Material baseado em:
  - MIT Introduction to Deep Learning, Ava Amini. 2023.